Actividad práctica: diagnostica tu árbol de decisión

Árboles de decisión para regresión · Dataset: **Diamantes** · Tiempo: 50 minutos · Trabajo en equipo

Equipo:	
Integrantes:	

Contexto

Una joyería quiere una herramienta que sugiera el precio de venta de un diamante a partir de sus características, para no depender solo del tasador. Los contrataron como analistas para decidir si un árbol de decisión puede predecir **precio_usd** con suficiente precisión. Tienen los datos y un script que entrena y mide los árboles, pero el script no interpreta nada: esa es su tarea.

Objetivos

Al terminar, el equipo podrá: (1) diagnosticar sobreajuste y subajuste comparando métricas de entrenamiento y prueba; (2) recorrer las reglas de un árbol para predecir un caso a mano; (3) justificar la elección de max_depth con evidencia; (4) interpretar la importancia de variables en el contexto del problema; (5) comunicar el error del modelo en unidades reales.

Sus datos

Archivo `diamantes_precio.csv`. Fuente: OpenML 42225 (diamonds); muestra aleatoria de 5 000 de 53 940.

Columna	Significado
quilates	peso del diamante (1 quilate = 0.2 g)
corte	calidad del corte: regular, bueno, muy_bueno, premium, ideal (de peor a mejor)
color	de D (incoloro, el mejor) a J
claridad	inclusiones internas: I1 (peor), SI2, SI1, VS2, VS1, VVS2, VVS1, IF (sin inclusiones)
profundidad_pct	alto total entre diámetro promedio, en %
tabla_pct	ancho de la cara superior respecto a la parte más ancha, en %
largo_mm, ancho_mm, alto_mm	medidas del diamante (mm)
precio_usd	**objetivo:** precio de venta (USD)

Materiales

• Esta carpeta: **actividad.py**, **diamantes_precio.csv** y esta hoja.
• Python 3 con `pip install pandas scikit-learn matplotlib`, o Google Colab subiendo actividad.py y el CSV.

Instrucciones

1. Ejecuten el script como indica la guía de la pregunta 4. Las gráficas quedan en `salidas/`.
2. Respondan las partes A a F en orden. Cada respuesta debe citar números de **su** corrida.
3. No cambien la semilla ni el código: el profesor revisa con los mismos resultados.

Parte A. Los datos (5 min)

4. ¿Cuántas filas y cuántas variables finales usó el modelo? ¿Qué mide **precio_usd** y en qué unidades?

Guía. Abran una terminal **dentro de esta carpeta** y ejecuten:
`python actividad.py > salida.txt` (en Mac/Linux puede ser `python3`).
Sin argumentos, el script usa el único CSV de la carpeta. Es lo mismo que escribir `python actividad.py diamantes_precio.csv`. El argumento opcional `--objetivo <columna>` sirve para predecir otra columna; en esta actividad **no** lo usen, porque el objetivo ya es la última columna. `> salida.txt` guarda todo lo que imprime el script en un archivo.
Abran `salida.txt` y busquen en el **PASO 1** la línea `Archivo: ... | N filas | M variables de entrada` y, más abajo, `- Variables finales:` K. Si K es distinto de M, la pregunta 5 les pedirá explicar por qué. El significado y las unidades de precio_usd están en la tabla "Sus datos".

5. Escribe el rango y el promedio de precio_usd. ¿El script eliminó o transformó algo? ¿Qué y por qué crees que fue necesario?

Guía. Al final del PASO 1 está la línea `'precio_usd': mínimo ... | máximo ... | promedio ...`. Las líneas que empiezan con `-` dicen qué hizo el script: columnas o filas eliminadas, o columnas de texto convertidas a 0/1 ("one-hot": una columna de texto como *color* se vuelve varias columnas *color_D*, *color_E*... con 1 si el dato tiene ese valor y 0 si no). Para el "por qué", piensen qué tipo de datos puede comparar un árbol contra un umbral como `<= 2.5`.

Parte B. Diagnóstico de los tres árboles (10 min)

6. Completa la tabla con los resultados de tu corrida (Brecha = R^2 train – R^2 test).

Guía. Copien los valores del **PASO 4. Métricas**: cada fila es un modelo y las columnas son *R^2 train*, *R^2 test*, *MAE test* y *hojas*. La brecha la calculan ustedes: por ejemplo, si R^2 train = 0.90 y R^2 test = 0.70, la brecha es 0.90 – 0.70 = 0.20. Una brecha grande significa que el modelo acierta mucho más con datos que ya vio que con datos nuevos. Desde la pregunta 7 ya no hay guía: usen lo que aprendieron aquí para encontrar cada dato en la salida.

Modelo	R^2 train	R^2 test	Brecha	MAE test	Hojas
Sin límites					
max_depth=3					
Ajustado (GridSearch)					

7. ¿Qué árbol tiene sobreajuste y cuál subajuste (si alguno)? Justifica con la brecha de cada uno. Si en tu dataset no se ve alguno de los dos, dilo y explica por qué.

Parte C. Predicción a mano (10 min)

8. Toma el "Caso para predecir a mano" (PASO 7) y recórrelo en las reglas del árbol max_depth=3 (PASO 6). Escribe cada pregunta del camino, el valor del caso y si vas a la izquierda o derecha.

Pregunta del nodo	Valor del caso	¿Izquierda o derecha?

9. ¿En qué hoja terminaste y qué valor de precio_usd predice? Compáralo con el valor real: ¿la diferencia es mayor o menor que el MAE del árbol max_depth=3? ¿Qué significa eso?

Parte D. ¿Qué tan profundo? (10 min)

10. Con la tabla del PASO 8 y curva_profundidad.png, recomienda un max_depth. Justifica con valores de R^2 en train y test.

11. Compara tu recomendación con lo que eligió GridSearchCV. Si no coinciden, explica por qué puede pasar (pista: GridSearch no mira el test y también ajusta min_samples_leaf).

Parte E. Variables importantes (5 min)

12. Nombra las 3 variables más importantes (PASO 5). Con lo que sabes del tema, ¿tiene sentido? Explica una.

13. Al comprar un diamante, el peso en quilates suele ser lo primero que se toma en cuenta. Compara la importancia de quilates con la de las medidas (largo, ancho, alto). ¿Por qué crees que el árbol las valora así?

Parte F. Recomendación al cliente (10 min)

14. En 4 a 6 líneas, dirigidas a alguien que no sabe de ciencia de datos: ¿usarías este modelo? Incluye el error típico en dólares (USD) (no solo R^2), una limitación y una mejora concreta que probarías.

Producto a entregar

Un PDF por equipo, llamado `equipo_<número>.pdf`, con las respuestas 4 a 14 numeradas, la tabla de la parte B y las imágenes **arbol_depth3.png** y **curva_profundidad.png**. Entrega al terminar la clase.

Criterios de éxito

[ ] Cada afirmación cita un número de su propia corrida (no de la presentación ni de otro equipo).
[ ] El diagnóstico de sobreajuste/subajuste compara train contra test, no solo un valor.
[ ] El camino en el árbol es correcto: cada comparación con el umbral lleva al lado que corresponde.
[ ] El max_depth recomendado está justificado con la curva y se contrasta con GridSearchCV.
[ ] La interpretación de variables usa conocimiento del tema, no solo repite el ranking.
[ ] La recomendación expresa el error en unidades reales y la entendería alguien sin formación técnica.

Rúbrica de evaluación (100 puntos)

Puntaje de cada criterio = peso × nivel ÷ 4. Ejemplo: nivel 3 en un criterio de 20 puntos da 15.

Criterio (preguntas)	Peso	4 Excelente	3 Bueno	2 En desarrollo	1 Insuficiente
1. Lectura de datos y diagnóstico de ajuste (4–7)	25	Reporta filas, variables, objetivo con unidades, rango y transformaciones. Tabla completa y correcta. Identifica sobreajuste y subajuste (o explica por qué no aparecen) comparando train contra test con la brecha de cada modelo.	Datos y tabla correctos. Diagnóstico correcto, pero justifica con la brecha solo un modelo o sin dar el valor.	Tabla con errores o incompleta, o diagnóstico basado en un solo valor (solo test o solo train).	Faltan la tabla o el diagnóstico, o los números no corresponden a su dataset.
2. Predicción a mano con el árbol (8–9)	20	Escribe las 3 preguntas del camino con el valor del caso y el lado correcto. Llega a la hoja correcta, calcula la diferencia con el valor real y la compara con el MAE explicando qué significa.	Camino y hoja correctos. Comparación con el MAE sin interpretación.	Un paso equivocado (por ejemplo, el lado de una variable 0/1) o falta la comparación con el MAE.	Camino incorrecto en dos o más pasos, o no hay recorrido.
3. Elección de max_depth (10–11)	20	Recomienda un valor donde se estabiliza el R^2 de test. Lo justifica con valores de train y test de la curva y explica la diferencia o coincidencia con GridSearchCV.	Valor razonable justificado con la curva. Comparación con GridSearch superficial.	Valor sin citar la curva, o elegido con el R^2 de train. Comparación con GridSearch ausente o errónea.	Sin recomendación o sin justificación.
4. Interpretación de variables (12–13)	15	Nombra las 3 más importantes y explica al menos una con conocimiento del tema. Responde la pregunta 13 con una razón plausible apoyada en sus resultados (por ejemplo, variables correlacionadas o redundantes, interacción entre variables).	Las 3 correctas con una explicación del tema. Respuesta a la 13 vaga o sin apoyo en sus resultados.	Solo repite el ranking, o concluye que una variable "no influye" porque su importancia es 0.	Variables incorrectas o no responde.
5. Recomendación al cliente (14)	20	Decisión clara (usar o no, y para qué). Error típico en las unidades del objetivo comparado con su escala. Una limitación y una mejora concretas de su dataset. Se entiende sin formación técnica.	Decisión con error en unidades. Limitación o mejora genérica.	La decisión solo se apoya en R^2, o falta la limitación o la mejora.	Sin decisión, o la recomendación contradice sus resultados.