Actividad práctica: diagnostica tu árbol de decisión

Árboles de decisión para regresión · Dataset: **Salarios en EUA (1985)** · Tiempo: 50 minutos · Trabajo en equipo

Equipo:	
Integrantes:	

Contexto

Un área de recursos humanos quiere estimar el salario por hora que corresponde a un candidato según su perfil. Para probar la idea usa una encuesta de 1985 de Estados Unidos. Los contrataron como analistas para decidir si un árbol de decisión puede predecir **salario_usd_hora** con suficiente precisión. Tienen los datos y un script que entrena y mide los árboles, pero el script no interpreta nada: esa es su tarea.

Objetivos

Al terminar, el equipo podrá: (1) diagnosticar sobreajuste y subajuste comparando métricas de entrenamiento y prueba; (2) recorrer las reglas de un árbol para predecir un caso a mano; (3) justificar la elección de max_depth con evidencia; (4) interpretar la importancia de variables en el contexto del problema; (5) comunicar el error del modelo en unidades reales.

Sus datos

Archivo `salarios_1985.csv`. Fuente: OpenML 534 (Current Population Survey, 1985).

Columna	Significado
educacion_anios	años de estudio
experiencia_anios	años de experiencia laboral
edad	años
sexo	mujer u hombre
vive_en_sur	si vive en el sur de EUA
sindicato	si pertenece a un sindicato
raza	blanca, hispana u otra
ocupacion	gerencia, ventas, administrativo, servicios, profesional u otra
sector	manufactura, construccion u otro
casado	si o no
salario_usd_hora	**objetivo:** salario por hora (USD)

Materiales

• Esta carpeta: **actividad.py**, **salarios_1985.csv** y esta hoja.
• Python 3 con `pip install pandas scikit-learn matplotlib`, o Google Colab subiendo actividad.py y el CSV.

Instrucciones

1. Ejecuten el script como indica la guía de la pregunta 4. Las gráficas quedan en `salidas/`.
2. Respondan las partes A a F en orden. Cada respuesta debe citar números de **su** corrida.
3. No cambien la semilla ni el código: el profesor revisa con los mismos resultados.

Parte A. Los datos (5 min)

4. ¿Cuántas filas y cuántas variables finales usó el modelo? ¿Qué mide **salario_usd_hora** y en qué unidades?

Guía. Abran una terminal **dentro de esta carpeta** y ejecuten:
`python actividad.py > salida.txt` (en Mac/Linux puede ser `python3`).
Sin argumentos, el script usa el único CSV de la carpeta. Es lo mismo que escribir `python actividad.py salarios_1985.csv`. El argumento opcional `--objetivo <columna>` sirve para predecir otra columna; en esta actividad **no** lo usen, porque el objetivo ya es la última columna. `> salida.txt` guarda todo lo que imprime el script en un archivo.
Abran `salida.txt` y busquen en el **PASO 1** la línea `Archivo: ... | N filas | M variables de entrada` y, más abajo, `- Variables finales:` K. Si K es distinto de M, la pregunta 5 les pedirá explicar por qué. El significado y las unidades de salario_usd_hora están en la tabla "Sus datos".

5. Escribe el rango y el promedio de salario_usd_hora. ¿El script eliminó o transformó algo? ¿Qué y por qué crees que fue necesario?

Guía. Al final del PASO 1 está la línea `'salario_usd_hora': mínimo ... | máximo ... | promedio ...`. Las líneas que empiezan con `-` dicen qué hizo el script: columnas o filas eliminadas, o columnas de texto convertidas a 0/1 ("one-hot": una columna de texto como *color* se vuelve varias columnas *color_D*, *color_E*... con 1 si el dato tiene ese valor y 0 si no). Para el "por qué", piensen qué tipo de datos puede comparar un árbol contra un umbral como `<= 2.5`.

Parte B. Diagnóstico de los tres árboles (10 min)

6. Completa la tabla con los resultados de tu corrida (Brecha = R^2 train – R^2 test).

Guía. Copien los valores del **PASO 4. Métricas**: cada fila es un modelo y las columnas son *R^2 train*, *R^2 test*, *MAE test* y *hojas*. La brecha la calculan ustedes: por ejemplo, si R^2 train = 0.90 y R^2 test = 0.70, la brecha es 0.90 – 0.70 = 0.20. Una brecha grande significa que el modelo acierta mucho más con datos que ya vio que con datos nuevos. Desde la pregunta 7 ya no hay guía: usen lo que aprendieron aquí para encontrar cada dato en la salida.

Modelo	R^2 train	R^2 test	Brecha	MAE test	Hojas
Sin límites					
max_depth=3					
Ajustado (GridSearch)					

7. ¿Qué árbol tiene sobreajuste y cuál subajuste (si alguno)? Justifica con la brecha de cada uno. Si en tu dataset no se ve alguno de los dos, dilo y explica por qué.

Parte C. Predicción a mano (10 min)

8. Toma el "Caso para predecir a mano" (PASO 7) y recórrelo en las reglas del árbol max_depth=3 (PASO 6). Escribe cada pregunta del camino, el valor del caso y si vas a la izquierda o derecha.

Pregunta del nodo	Valor del caso	¿Izquierda o derecha?

9. ¿En qué hoja terminaste y qué valor de salario_usd_hora predice? Compáralo con el valor real: ¿la diferencia es mayor o menor que el MAE del árbol max_depth=3? ¿Qué significa eso?

Parte D. ¿Qué tan profundo? (10 min)

10. Con la tabla del PASO 8 y curva_profundidad.png, recomienda un max_depth. Justifica con valores de R^2 en train y test.

11. Compara tu recomendación con lo que eligió GridSearchCV. Si no coinciden, explica por qué puede pasar (pista: GridSearch no mira el test y también ajusta min_samples_leaf).

Parte E. Variables importantes (5 min)

12. Nombra las 3 variables más importantes (PASO 5). Con lo que sabes del tema, ¿tiene sentido? Explica una.

13. Compara la importancia de experiencia_anios con la de edad: ¿por qué crees que el árbol casi no usa una de ellas? Además, sexo_mujer aparece entre las importantes: ¿qué riesgo habría si una empresa usara este modelo para fijar sueldos?

Parte F. Recomendación al cliente (10 min)

14. En 4 a 6 líneas, dirigidas a alguien que no sabe de ciencia de datos: ¿usarías este modelo? Incluye el error típico en dólares por hora (USD/h) (no solo R^2), una limitación y una mejora concreta que probarías.

Producto a entregar

Un PDF por equipo, llamado `equipo_<número>.pdf`, con las respuestas 4 a 14 numeradas, la tabla de la parte B y las imágenes **arbol_depth3.png** y **curva_profundidad.png**. Entrega al terminar la clase.

Criterios de éxito

[ ] Cada afirmación cita un número de su propia corrida (no de la presentación ni de otro equipo).
[ ] El diagnóstico de sobreajuste/subajuste compara train contra test, no solo un valor.
[ ] El camino en el árbol es correcto: cada comparación con el umbral lleva al lado que corresponde.
[ ] El max_depth recomendado está justificado con la curva y se contrasta con GridSearchCV.
[ ] La interpretación de variables usa conocimiento del tema, no solo repite el ranking.
[ ] La recomendación expresa el error en unidades reales y la entendería alguien sin formación técnica.

Rúbrica de evaluación (100 puntos)

Puntaje de cada criterio = peso × nivel ÷ 4. Ejemplo: nivel 3 en un criterio de 20 puntos da 15.

Criterio (preguntas)	Peso	4 Excelente	3 Bueno	2 En desarrollo	1 Insuficiente
1. Lectura de datos y diagnóstico de ajuste (4–7)	25	Reporta filas, variables, objetivo con unidades, rango y transformaciones. Tabla completa y correcta. Identifica sobreajuste y subajuste (o explica por qué no aparecen) comparando train contra test con la brecha de cada modelo.	Datos y tabla correctos. Diagnóstico correcto, pero justifica con la brecha solo un modelo o sin dar el valor.	Tabla con errores o incompleta, o diagnóstico basado en un solo valor (solo test o solo train).	Faltan la tabla o el diagnóstico, o los números no corresponden a su dataset.
2. Predicción a mano con el árbol (8–9)	20	Escribe las 3 preguntas del camino con el valor del caso y el lado correcto. Llega a la hoja correcta, calcula la diferencia con el valor real y la compara con el MAE explicando qué significa.	Camino y hoja correctos. Comparación con el MAE sin interpretación.	Un paso equivocado (por ejemplo, el lado de una variable 0/1) o falta la comparación con el MAE.	Camino incorrecto en dos o más pasos, o no hay recorrido.
3. Elección de max_depth (10–11)	20	Recomienda un valor donde se estabiliza el R^2 de test. Lo justifica con valores de train y test de la curva y explica la diferencia o coincidencia con GridSearchCV.	Valor razonable justificado con la curva. Comparación con GridSearch superficial.	Valor sin citar la curva, o elegido con el R^2 de train. Comparación con GridSearch ausente o errónea.	Sin recomendación o sin justificación.
4. Interpretación de variables (12–13)	15	Nombra las 3 más importantes y explica al menos una con conocimiento del tema. Responde la pregunta 13 con una razón plausible apoyada en sus resultados (por ejemplo, variables correlacionadas o redundantes, interacción entre variables).	Las 3 correctas con una explicación del tema. Respuesta a la 13 vaga o sin apoyo en sus resultados.	Solo repite el ranking, o concluye que una variable "no influye" porque su importancia es 0.	Variables incorrectas o no responde.
5. Recomendación al cliente (14)	20	Decisión clara (usar o no, y para qué). Error típico en las unidades del objetivo comparado con su escala. Una limitación y una mejora concretas de su dataset. Se entiende sin formación técnica.	Decisión con error en unidades. Limitación o mejora genérica.	La decisión solo se apoya en R^2, o falta la limitación o la mejora.	Sin decisión, o la recomendación contradice sus resultados.